

PM2.5 in Northern Thailand: from raw data to a recommendation

จัดทำโดย

พิมพ์ภัทร มยุระสาคร รหัสนักศึกษา 690631022

เสนอ

ผศ. ดร. ภาสกร แชมป์ประเสริฐ

รายงานนี้เป็นส่วนหนึ่งของวิชา 27070 Data Science Programming

ภาคเรียนที่ 1 ปีการศึกษา 2569

มหาวิทยาลัยเชียงใหม่

1. Problem Background

ในทุกๆ ปี ระหว่างช่วงเดือนมกราคมถึงเมษายน อากาศในภาคเหนือของประเทศไทยเข้าสู่วิกฤตมลพิษทางอากาศขั้นรุนแรงจนเป็นอันตรายต่อระบบทางเดินหายใจอย่างมาก ต้นเหตุหลักเกิดจากการเผาเศษวัสดุทางการเกษตร ไฟป่า และมลพิษข้ามพรมแดน ซึ่งเมื่อเผชิญกับเงื่อนไขทางอุตุนิยมวิทยาที่มีสภาพอากาศนิ่ง (Atmospheric Stagnation) ร่วมกับลักษณะทางกายภาพของเมืองเชียงใหม่ที่เป็นหุบเขาล้อมรอบด้วยภูเขาสูง ส่งผลให้ฝุ่นละอองขนาดเล็กถูกกักขังและสะสมตัวอยู่ในแอ่งกระทะอย่างหลีกเลี่ยงไม่ได้

วิกฤตการณ์ดังกล่าวส่งผลกระทบเป็นวงกว้าง ส่งผลให้โรงเรียนต้องประกาศปิดเรียนชั่วคราว และเกิดความเสียหายต่ออุตสาหกรรมการท่องเที่ยวในจังหวัดเชียงใหม่อย่างรุนแรง เมืองเชียงใหม่ยังถูกจัดอันดับให้อยู่ในกลุ่มเมืองที่มีมลพิษทางอากาศสูงที่สุดในโลกหลายครั้ง โดยเฉพาะรายงานสถานการณ์คุณภาพอากาศจาก IQAir (IQAir, 2026) ยอดผู้ป่วยเข้ารับการรักษาในโรงพยาบาลด้วยโรคระบบทางเดินหายใจยังพุ่งสูงขึ้นอย่างมีนัยสำคัญ หลักฐานทางวิทยาศาสตร์ชี้ให้เห็นว่าการได้รับฝุ่น PM2.5 ในเชียงใหม่สัมพันธ์กับภาวะความเครียดระดับเซลล์ (Oxidative Stress) ในร่างกาย (Assi et al., 2025) รวมถึงส่งผลกระทบโดยตรงต่อสุขภาพดวงตาของประชาชนในพื้นที่อย่างเด่นชัด (Waikare et al., 2024)

2. Approach

คำถามหลักของงานนี้คือ: ฝุ่น PM2.5 ในเชียงใหม่รุนแรงแค่ไหน เกิดขึ้นเมื่อไหร่และที่ไหน สามารถทำนายคุณภาพอากาศของวันพรุ่งนี้ได้แม่นยำพอที่จะใช้เป็นระบบเตือนภัยหรือไม่ และควรมีมาตรการรับมืออย่างไร

Hypothesis: คาดว่าความเร็วลมจะเป็นปัจจัยอากาศหลักที่ควบคุมการสะสมของ PM2.5 โดยตั้งสมมติฐานว่าลมสงบจะทำให้มลพิษตกค้างอยู่ในแอ่งหุบเขา และคาดว่าอุณหภูมิที่สูงขึ้นในหน้าร้อนจะสัมพันธ์กับคุณภาพอากาศที่แย่ลง

3. Method

3.1. Data sources

- Open-Meteo Air Quality (PM2.5 and other pollutants)
 - latitude: 18.7904
 - longitude: 98.9847
 - hourly: ["pm10", "pm2_5", "carbon_monoxide", "dust"]
 - time zone: Asia/Bangkok
 - start date: 2023-01-01
 - end date: 2025-04-30
- Open-Meteo Archive (weather)
 - latitude: 18.7904
 - longitude: 98.9847
 - start date: "2023-01-01"
 - end date: "2025-04-30"

- hourly: ["temperature_2m", "relative_humidity_2m", "wind_speed_10m", "precipitation"]
- time zone: "Asia/Bangkok"

3.2. Cleaning and joining

- การปรับมาตรฐานเขตเวลา (Timezone Standardization): แปลงคอลัมน์เวลา date ของทั้งชุดข้อมูลคุณภาพอากาศ (Air Quality) และชุดข้อมูลสภาพอากาศ (Weather) ให้เป็นเขตเวลา Asia/Bangkok (+07:00) เพื่อให้สอดคล้องกับเวลาท้องถิ่นของประเทศไทย
- ตรวจสอบจำนวนแถว ประเภทข้อมูล (Data Types) และค่าที่หายไป (Missing Values) ก่อนทำการรวมข้อมูล Features
- ทำการรวมชุดข้อมูลทั้งสองเข้าด้วยกันโดยใช้คีย์ date

3.3. Features

- AQ
 - pm10, pm2_5, carbon_monoxide, dust
- weather
 - temperature_2m, relative_humidity_2m, wind_speed_10m, precipitation

3.4. Target definition

- Classification: ตัวบ่งชี้สภาวะเกินมาตรฐาน PM2.5 ในวันพรุ่งนี้ ค่า $pm2.5 > 37.5 \mu g/m^3$

3.5. Split strategy

- การแบ่งตามลำดับเวลา (Time-based Split): แบ่งข้อมูลตามช่วงเวลาโดยไม่สับเปลี่ยนข้อมูล (No Random Shuffle) เช่น ใช้ข้อมูลปี 2023–2024 เป็น Train Set และใช้ข้อมูลปี 2025 เป็น Test Set
- การทำ Cross-Validation: ใช้ TimeSeriesSplit ในการประเมินโมเดล เพื่อป้องกันไม่ให้โมเดลเรียนรู้ข้อมูลในอนาคตก่อนอดีต

3.6. Models and baseline

- Baseline Model: ใช้ Persistence Model (คาดการณ์ว่าค่า PM2.5 พรุ่งนี้ = ค่า PM2.5 วันนี้) สำหรับ Regression และใช้ Majority Class สำหรับ Classification
- Models: ทดสอบด้วย Linear Regression, Logistic Regression, Random Forest Regressor และ Random Forest Classifier

4. Results


4.1. Statistical Testing Results (t-test)

ผลการทดสอบความแตกต่างของปัจจัยสภาพอากาศระหว่างวันปกติและวันฝุ่นสูง มีดังนี้

	variable	t_statistic	p_value	significant_p005
1	wind_speed_10m	-3.0243	0.002567124219722458	True
2	relative_humidity_2m	9.1962	2.802929938355764e-19	True
3	temperature_2m	-1.0276	0.30441886612514885	False


4.2. Data Visualization Insights

- Daily_PM2.5_and_PM10_in_Chiang_Mai_(2023-2025)




ฤดูกาลฝุ่น PM2.5 และ PM10 เริ่มต้นขึ้นในช่วงเดือนกุมภาพันธ์ และสิ้นสุดลงในเดือนเมษายน ของทุกปีอย่างเด่นชัด โดยปี 2023 มีค่าความเข้มข้นสูงสุด (Peak) สูงกว่าปี 2024 และ 2025

- Correlation Heatmap: PM2.5 & Weather Factors




ความชื้นสัมพัทธ์ (relative_humidity_2m) มีความสัมพันธ์ทิศทางตรงกันข้ามกับ PM2.5 สูงที่สุด ($r = -0.58$) ตามด้วย ปริมาณฝน ($r = -0.46$) ในขณะที่อุณหภูมิแทบไม่มีความสัมพันธ์เชิงเส้นกับระดับฝุ่น ($r = -0.01$)

- Weather Conditions on Bad Days vs Normal Days



ในวันฝุ่นสูง (High PM2.5) ค่ามัธยฐานของความชื้นสัมพัทธ์จะลดลงอย่างเห็นได้ชัด (59%) เมื่อเทียบกับวันปกติ (78%) สอดคล้องกับผลการทดสอบ t-test ที่มีนัยสำคัญทางสถิติ ($p < 0.0001$)

- Number of Days Exceeding PM2.5 Standard ($> 37.5 \mu\text{g}/\text{m}^3$) by Month



จำนวนวันที่ฝุ่นเกินเกณฑ์มาตรฐาน ($> 37.5 \mu\text{g}/\text{m}^3$) กระจุกตัวสูงสุดในเดือนมีนาคมของทุกปี โดยรวมแล้วปี 2023 มีจำนวนวันที่ฝุ่นเกินมาตรฐานมากที่สุด และมีแนวโน้มลดลงในปี 2024–2025

4.3. Model Performance

- Regression (ทำนายค่าเฉลี่ย PM2.5 ของวันพรุ่งนี้):

Model	Test MAE	Test RMSE	R ²	beats_baseline
Baseline	5.679	7.752	0.530	-
Linear Regression	5.135	7.307	0.582	Yes
Random Forest	5.909	8.238	0.469	no

- Classification (ทำนายว่าพรุ่งนี้เกิน $37.5 \mu\text{g}/\text{m}^3$ หรือไม่):

Model	Recall	Precision	F1	beats_baseline_recall
Baseline	0.000	0.000	0.000	-
Logistic Regression	0.906	0.362	0.518	yes
Random Forest Classifier	0.781	0.510	0.617	yes

เกิดจากปัญหา Overfitting ร่วมกับ Time-series Concept Drift เนื่องจาก Random Forest เป็นโมเดลที่มีความซับซ้อนสูง จึงจดจำรูปแบบ Noise ในข้อมูลอดีต (Train Set) มากเกินไป เมื่อนำมาทดสอบกับข้อมูลช่วงเวลาใหม่ใน Test Set (ปี 2025) ที่มีสภาพอากาศและรูปแบบฝุ่นเปลี่ยนไป โมเดล

จึงไม่สามารถปรับตัวได้ดี (Poor Generalization) ในขณะที่ Linear Regression เป็นโมเดลที่ไม่ซับซ้อน (Simpler Model) จึงไม่เกิด Overfitting และให้ผลลัพธ์บน Test Set ที่มั่นคงและดีกว่า Baseline ชัดเจน

4.4. What Didn't Work

Random Forest แพ้ทั้ง persistence baseline และ Linear Regression ในงาน regression (test MAE 5.909 vs. 5.135) ทั้งที่ตอน cross-validation ทำคะแนนดีกว่า (CV MAE 4.824 vs. 4.859) สัญญาณของ overfitting เพราะ Random Forest ซับซ้อนเกินไป จดจำ noise ของช่วง train (2023-2024) แล้ว generalize ไปปี 2025 ที่รูปแบบอากาศเปลี่ยนไปได้ไม่ดี

Linear Regression เองก็มี CV MAE std สูง (3.145) แสดงว่ายังไม่เสถียรเต็มที่ ส่วน Logistic Regression มี precision ต่ำ (0.362)

4.5. Discussion on Checkpoint Questions

C1 · Time

Show that your daily averages correspond to Thailand local days. Describe how you verified this rather than asserting it. If you fetched from two endpoints, show that their time axes agree.

C1 · answer in the report; note your evidence here

```
----- AQ -----
```

```
First timestamp: 2023-01-01 00:00:00+07:00
Last timestamp: 2025-04-30 23:00:00+07:00
Timezone info: Asia/Bangkok
```

```
----- Weather -----
```

```
First timestamp: 2023-01-01 00:00:00+07:00
Last timestamp: 2025-04-30 23:00:00+07:00
Timezone info: Asia/Bangkok
```

```
----- After Join -----
```

```
First timestamp: 2023-01-01 00:00:00+07:00
Last timestamp: 2025-04-30 23:00:00+07:00
Timezone info: Asia/Bangkok
```

C2 · The join

How many rows did each source have before joining, and how many after? If the number changed, account for every row. If it did not change, show how you checked.

C2

ก่อน join

Air Quality: 20424 แถว , Weather: 20424 แถว

หลัง join – 20424 แถว

โดยเช็คจากการ ใช้ `print(df_pm5_processed.shape)`

```
----- After Join -----  
  
First timestamp: 2023-01-01 00:00:00+07:00  
Last timestamp: 2025-04-30 23:00:00+07:00  
Timezone info: Asia/Bangkok  
<class 'pandas.DataFrame'>  
RangeIndex: 20424 entries, 0 to 20423  
Data columns (total 9 columns):  
#   Column                Non-Null Count  Dtype  
---  ---  
0   date                   20424 non-null  datetime64[us, Asia/Bangkok]  
1   pm10                   20424 non-null  float64  
2   pm2_5                  20424 non-null  float64  
3   carbon_monoxide        20424 non-null  float64  
4   dust                   20424 non-null  float64  
5   temperature_2m         20424 non-null  float64  
6   relative_humidity_2m   20424 non-null  float64  
7   wind_speed_10m         20424 non-null  float64  
8   precipitation           20424 non-null  float64  
dtypes: datetime64[us, Asia/Bangkok](1), float64(8)  
memory usage: 1.4 MB  
None  
(20424, 9)
```

C3 · Missing values

Report the percentage missing for every column. If any column is exactly 0.00% missing across years of data, explain what that implies about where the data came from.

C3

ทุกตัวมี missing 0% เป็นข้อมูลจาก Reanalysis/Atmospheric Model (Copernicus CAMS & ERA5) ซึ่งใช้คำนวณจากแบบจำลองทางคณิตศาสตร์และดาวเทียม จึงมีการประมวลผลเติมเต็มช่องว่าง (Grid Imputation) มาเรียบร้อยแล้วตั้งแต่ต้นทาง

	missing_count	missing_pct (%)
date	0	0.0
pm10	0	0.0
pm2_5	0	0.0
carbon_monoxide	0	0.0
dust	0	0.0

	missing_count	missing_pct (%)
date	0	0.0
temperature_2m	0	0.0
relative_humidity_2m	0	0.0
wind_speed_10m	0	0.0
precipitation	0	0.0

----- C3: Missing Values Inspection -----

	missing_count	missing_pct (%)
date	0	0.0
pm10	0	0.0
pm2_5	0	0.0
carbon_monoxide	0	0.0
dust	0	0.0
temperature_2m	0	0.0
relative_humidity_2m	0	0.0
wind_speed_10m	0	0.0
precipitation	0	0.0

C4 · Comparing places

If your analysis compares two or more locations, demonstrate that they actually return different data before you draw any spatial conclusion. State the evidence.

C4

- ศูนย์ราชการจังหวัดเชียงใหม่ (ด.ข้างเผือก อ.เมือง, เชียงใหม่)
วันที่: 2026-09-05 เวลา: 16:00 PM2.5 = 18.4 $\mu\text{g}/\text{m}^3$
- โรงเรียนพญาภิทยาลัย (ด.ศรีภูมิ อ.เมือง, เชียงใหม่)
วันที่: 2026-09-05 เวลา: 16:00 PM2.5 = 11.2 $\mu\text{g}/\text{m}^3$

จากค่าจริงจะเห็นได้ว่าแม้ว่าอยู่ในอำเภอเมืองเชียงใหม่เหมือนกัน ค่าฝุ่นก็ต่างกัน

C5 · Model versus baseline

State the baseline score and your model score side by side, on the same test set. If your cross-validation score and your test score disagree substantially, explain why.

C5				
Regression (ทำนายค่าเฉลี่ย PM2.5 ของวันพรุ่งนี้):				
Model	Test MAE	Test RMSE	R ²	beats_baseline
Baseline	5.679	7.752	0.530	-
Linear Regression	5.135	7.307	0.582	Yes
Random Forest	5.909	8.238	0.469	no
Classification (ทำนายว่าพรุ่งนี้เกิน 37.5 µg/m ³ หรือไม่):				
Model	Recall	Precision	F1	beats_baseline_recall
Baseline	0.000	0.000	0.000	-
Logistic Regression	0.906	0.362	0.518	yes
Random Forest Classifier	0.781	0.510	0.617	yes
เกิดจากปัญหา Overfitting ร่วมกับ Time-series Concept Drift เนื่องจาก Random Forest เป็นโมเดลที่มีความซับซ้อนสูง จึงจดจำรูปแบบ Noise ในข้อมูลอดีต (Train Set) มากเกินไป เมื่อนำมาทดสอบกับข้อมูลช่วงเวลาใหม่ใน Test Set (ปี 2025) ที่มีสภาพอากาศและรูปแบบฝุ่นเปลี่ยนไป โมเดลจึงไม่สามารถปรับตัวได้ดี (Poor Generalization) ในขณะที่ Linear Regression เป็นโมเดลที่ไม่ซับซ้อน (Simpler Model) จึงไม่เกิด Overfitting และให้ผลลัพธ์บน Test Set ที่มั่นคงและดีกว่า Baseline ชัดเจน				

C6 · Ground truth

Compare your data against Air4Thai station readings for at least one point in time. Report the difference. If they disagree, which one is right, and what does that mean for your conclusions?

C6

เมื่อเวลา 16:00 น. ของวันที่ 5 กันยายน 2569 Open-Meteo รายงานค่า PM2.5 ที่ $5.7 \mu\text{g}/\text{m}^3$ ในขณะที่สถานีตรวจวัดภาคพื้นดินของ Air4Thai บันทึกค่าได้ $18.4 \mu\text{g}/\text{m}^3$ (ข้างเผือก) และ $11.2 \mu\text{g}/\text{m}^3$ (โรงเรียนยุพราช)

Air4Thai มีความแม่นยำมากกว่าสำหรับสภาพในระดับท้องถิ่น เนื่องจากการตรวจวัดทางกายภาพโดยตรง Open-Meteo แสดงค่าเฉลี่ยของตารางเชิงพื้นที่ ทำให้เกิดการประเมินค่าต่ำกว่าความเป็นจริงอย่างเป็นระบบ

แม้ว่าค่าเกณฑ์สัมบูรณ์ ($> 37.5 \mu\text{g}/\text{m}^3$) ใน Open-Meteo อาจประเมินจำนวนวันที่มลพิษรุนแรงต่ำกว่าความเป็นจริง แต่ความสัมพันธ์เชิงสัมพัทธ์ที่ระบุ (เช่น ความสำคัญของความชื้นและความเร็วลม) และแนวโน้มตามฤดูกาลยังคงใช้ได้สำหรับการวิเคราะห์ทางสถิติ

- ศูนย์ราชการจังหวัดเชียงใหม่ (ด.ข้างเผือก อ.เมือง, เชียงใหม่)
วันที่: 2026-09-05 เวลา: 16:00 PM2.5 = $18.4 \mu\text{g}/\text{m}^3$

- โรงเรียนยุพราชวิทยาลัย (ด.ศรีภูมิ อ.เมือง, เชียงใหม่)
วันที่: 2026-09-05 เวลา: 16:00 PM2.5 = $11.2 \mu\text{g}/\text{m}^3$

time	pm2_5
16 2026-09-05T16:00	5.7

5. Conclusion

ความชื้นสัมพัทธ์ต่ำ (อากาศแห้ง $r = -0.58$) และความเร็วลมต่ำ (อากาศนิ่ง) เป็นปัจจัยทางอุตุนิยมวิทยาหลักที่เอื้อต่อการสะสมตัวของฝุ่น PM2.5 ในเชียงใหม่ โดยความชื้นสัมพัทธ์เป็นตัวชี้หน้าที่ชัดเจนที่สุด แต่อุณหภูมิไม่มีความแตกต่างอย่างมีนัยสำคัญทางสถิติระหว่างวันปกติและวันฝุ่นสูง ($p > 0.05$) ผลการศึกษาจึงปฏิเสธสมมติฐานเรื่องอุณหภูมิ (Reject Hypothesis)

5.1. ข้อเสนอแนะเชิงนโยบายและการนำไปใช้จริง

- กลุ่มเป้าหมาย (Target Audience) : Governor
- สิ่งที่จะแนะนำ : เสนอให้ผู้ว่าฯ สั่งการจัดตั้ง "ระบบแจ้งเตือนภัยและมาตรการควบคุมฝุ่นล่วงหน้า 24 ชั่วโมง (24-Hour Preemptive Dust Control System)" โดยใช้เงื่อนไขจากผลการวิเคราะห์สถิติ:
 - เมื่อโมเดลพยากรณ์พบว่าวันพรุ่งนี้ ความชื้นสัมพัทธ์จะต่ำกว่า 60% ($r = -0.58$) ร่วมกับความเร็วมลต่ำกว่า 4 m/s ซึ่งเป็นสภาวะอากาศปิดที่ฝุ่นจะสะสมตัวรุนแรง
 - สั่งการเทศบาล/ปภ. ระดมรถฉีดพ่นละอองน้ำเพิ่มความชื้นตามจุดเสี่ยงหนาแน่นในเขตเมืองก่อนฝุ่นก่อตัว

- ส่งการสาธารณสุขจังหวัดเตรียมเปิด Clean Air Shelter และกระจายหน้ากาก N95 ให้กลุ่มเสี่ยงล่วงหน้า 1 วัน
- What happens on the days your model is wrong?
 - ประชาชนจะไม่ได้รับการแจ้งเตือนล่วงหน้า
 - วิธีป้องกันคือ ให้เจ้าหน้าที่รีเช็คสภาพอากาศซ้ำก่อนออกประกาศมาตรการที่กระทบวงกว้าง
- What would you need to give a stronger recommendation?
 - ข้อมูลตรวจวัดจริงภาคพื้นดินหลายๆ พิกัด (Multi-station Ground-truth) เพื่อแก้ปัญหา Micro-climate ในเขตเมือง (ดังที่พบความต่างระหว่างสถานีช้างเผือก $18.4 \mu\text{g}/\text{m}^3$ กับยุพราช $11.2 \mu\text{g}/\text{m}^3$ และข้อมูลจุดความร้อน (Hotspots) ย้อนหลังมากกว่า 2.5 ปี

6. Use of AI tools

Where you used it	What you asked for	What you changed or rejected
src/analyse.py — กราฟเปรียบเทียบวันฝุ่นสูง vs วันปกติ	คำแนะนำว่าควรใช้กราฟแบบไหน	แนะนำให้ใช้ scatterplot เอา แต่รู้สึกว่ามันดูไม่ค่อยรู้เรื่อง เลยเปลี่ยนมาใช้เป็น boxplot แทน
src/model.py — ออกแบบ feature	คำแนะนำเรื่อง feature ที่ใช้ได้กับงานทำนาย	ปรับ feature list
Checkpoint C6 (ground truth)	วิธีเทียบ Open-Meteo กับ Air4Thai	แก้ไขเองว่าต้องดึง Open-Meteo ของวันเดียวกับที่ดึง Air4Thai ไม่ใช่ใช้ข้อมูลเก่าที่มีอยู่แล้ว (ตอนแรกเข้าใจผิดว่าใช้ข้อมูลเดิมได้)

7. REFERENCES

Assi, S., et al. (2025). Assessment of urinary oxidative stress biomarkers associated with fine particulate matter (PM2.5) exposure in Chiang Mai, Thailand. PeerJ, 13, e19047.

<https://doi.org/10.7717/peerj.19047>

IQAir. (2026, April 16). Chiang Mai among top 10 most polluted cities in the world. IQAir Newsroom. <https://www.iqair.com/th/newsroom/chiang-mai-among-top-10-most-polluted-cities-in-the-world-4-16-2026>

Waikare, A., et al. (2024). Impact of fine particulate matter (PM2.5) on ocular health among people living in Chiang Mai, Thailand. Scientific Reports, 14, Article 27288.

<https://doi.org/10.1038/s41598-024-77288-8>